

# MANIFOLD

## Un Motor Matemático para Mapear Vulnerabilidades

Proyecto MANIFOLD

Whitepaper v0.1 — borrador de trabajo, no revisado por pares

### Abstract

MANIFOLD trata un artefacto de software no como un conjunto de reglas a emparejar, sino como un *objeto matemático*: un grafo tipado y ponderado enriquecido con estructura *algebraica*, *espectral*, *topológica* y *geométrica*. Sobre ese objeto se computa un campo escalar de **potencial de vulnerabilidad**  $V(x)$ , que hace emerger las regiones anómalas como *rasgos* geométricos / topológicos / espectrales en lugar de coincidencias literales de cadenas. Un **agente LLM autónomo** navega el “manifold” resultante, formula hipótesis sobre esas regiones y despacha **verificadores formales** (SMT, ejecución simbólica, interpretación abstracta) que confirman o refutan cada hipótesis — cerrando el ciclo entre intuición estadística y prueba matemática. Este documento define la representación intermedia, formaliza cada capa matemática, enuncia las leyes de mapeo que conectan rasgos matemáticos con clases de vulnerabilidad, y especifica la arquitectura del agente y la hoja de ruta.

## 1 Motivación

Los escáneres tradicionales (SAST/DAST) enumeran patrones sintácticos. Son frágiles: pasan por alto vulnerabilidades novedosas y ahogan al analista en falsos positivos. Faltan dos capacidades:

- (1) Una *representación unificada y cuantitativa* de la “estructura del programa” sobre la cual proyectar y fusionar muchas señales *independientes*.
- (2) Un *ciclo de razonamiento* que convierta “región sospechosa” en “vulnerabilidad probada” — el LLM aporta la intuición, la matemática aporta la prueba.

MANIFOLD proporciona ambas.

## 2 La idea central




Figure 1: El pipeline: un artefacto se convierte en un grafo tipado, enriquecido con estructura matemática en un campo escalar de vulnerabilidad  $V(x)$ , que un agente LLM navega; un verificador formal confirma o refuta cada hipótesis y el resultado se re-embebe en el manifold.

Una vulnerabilidad *no* es un patrón; es una *violación de una invariante estructural* (una condición de naturalidad rota, un ciclo persistente, un cuello de botella de curvatura negativa, un flujo de taint que cruza un corte espectral de confianza). Cada capa detecta un *tipo* distinto de violación de invariante, y el campo fusionado  $V(x)$  ordena las regiones para que el agente las inspeccione.

### 3 La Representación Intermedia (IR)

**Definición 1 (Grafo de programa).** Un *grafo de programa* es una tupla  $G = (V, E, \tau_V, \tau_E, \omega)$  donde

- $V$  es un conjunto finito de *nodos* (módulos, funciones, bloques, sentencias, llamadas, variables, fuentes, sumideros);
- $E \subseteq V \times V$  es un conjunto de *aristas* dirigidas;
- $\tau_V : V \rightarrow \mathbb{N}_K$  asigna a cada nodo un *tipo* de  $K = \{\text{módulo, función, bloque, sentencia, llamada, asignación, variable, parámetro, fuente, sumidero, gate}\}$ ;
- $\tau_E : E \rightarrow \mathcal{T}$  asigna a cada arista un *tipo*  $\mathcal{T} = \{\text{control, dato, llamada, taint, confianza, auth}\}$ ;
- $\omega : E \rightarrow \mathbb{R}_{\geq 0}$  asigna a cada arista un *peso* no negativo (por defecto 1).

La IR es la única fuente de verdad. Cada adaptador (código fuente, binario, API web, agente LLM) debe producir un grafo de programa; cada análisis lo consume. El esquema es agnóstico al lenguaje y serializable a JSON (las capas Python y Rust comparten el mismo esquema).

### 4 Capas matemáticas

Para cada capa fijamos un subgrafo por tipo de arista  $\tau_E$ , y luego computamos estructura.

#### 4.1 Capa espectral (teoría algebraica de grafos)

Para un tipo de arista  $t$ , definimos la *adyacencia* simétrica  $A_t$  y el *grado*  $D_t$ , y el *Laplaciano combinatorio*

$$L_t = D_t - A_t.$$

$L_t$  es semidefinido positivo; su espectro  $0 = \lambda_1 \leq \lambda_2 \leq \dots$  codifica la estructura global:

- $\lambda_2$  es la *conectividad algebraica* (valor de Fiedler). Su autovector  $f_2$  — el *vector de Fiedler* — induce un corte canónico  $S^+ = \{v : f_2(v) \geq 0\}$ .
- El *embedding espectral*  $\Phi^{(d)}(v) = (f_2(v), f_3(v), \dots, f_{d+1}(v))$  mapea nodos a  $\mathbb{R}^d$ .
- La desigualdad de Cheeger acota el cociente de cuello de botella  $h(G)$  por  $\frac{\lambda_2}{2} \leq h(G) \leq \sqrt{2 d_{\max} \lambda_2}$ .

**Señal 1 (anomalía espectral).** El error de reconstrucción de un nodo bajo una reconstrucción de eigenmap de bajo rango, y su distancia al corte de Fiedler, se usan como puntajes de anomalía.

## 4.2 Capa topológica (homología persistente)

Del grafo de programa construimos una *filtración* de complejos simpliciales (p. ej. un complejo de Vietoris–Rips o de bandera sobre la métrica de caminos más cortos, o una filtración guiada por  $\omega$ ). La homología persistente produce, para cada dimensión  $k$ , un *diagrama de persistencia*  $\text{Dgm}_k$  de pares nacimiento–muerte.  $\beta_0$  cuenta componentes,  $\beta_1$  cuenta ciclos independientes; los puntos lejos de la diagonal tienen alta persistencia. El algoritmo **Mapper** (Singh–Mémoli–Carlsson) construye un *nervio* navegable a partir de una función filtro  $f : V \rightarrow \mathbb{R}$ , produciendo el mapa que da nombre al proyecto.

## 4.3 Capa geométrica (curvatura discreta)

La *curvatura de Ollivier–Ricci* de una arista  $(u, v)$  es

$$\kappa(u, v) = 1 - \frac{W_1(m_u, m_v)}{d(u, v)},$$

con medidas de paseo aleatorio perezoso  $m_u, m_v$  y distancia de Wasserstein-1  $W_1$ . La curvatura negativa marca *embudos* por los que pasan muchos caminos más cortos. La *curvatura de Forman–Ricci* (sin pesos) es  $\kappa_F(u, v) = 4 - \deg(u) - \deg(v)$ , marcando de forma barata los nodos de alto grado.

## 4.4 Capa algebraica (retículos y teoría de categorías)

*Interpretación abstracta.* El *retículo de taint*  $\mathbb{T} = \{\perp = \text{limpio} \sqsubseteq \top = \text{manchado}\}$  (un retículo producto sobre etiquetas) da una *conexión de Galois*  $(\alpha, \gamma)$  entre la semántica recolectora concreta y el dominio abstracto de taint, garantizando solidez. *Teoría de categorías.* El programa es una categoría **Prog**; los efectos son mónadas, la autorización es un funtor  $F : \mathbf{Prog} \rightarrow \mathbf{Auth}$ . **Ley de diseño (naturalidad del taint):** una vulnerabilidad es un flujo de taint que rompe el cuadrado de naturalidad de  $F$ .

## 4.5 Capa formal (ejecución simbólica y model checking)

La ejecución simbólica calcula una condición de camino  $\Phi$  y un estado simbólico  $\sigma$ ; un solucionador SMT comprueba  $\text{SAT}(\Phi \wedge \text{malo})$ , cuyo modelo es un exploit concreto. La alcanzabilidad es la fórmula CTL **EF** malo; la propagación de taint es un autómata finito cuyo lenguaje aceptado es exactamente el conjunto de caminos fuente  $\rightarrow$  sumidero.

# 5 El campo escalar de vulnerabilidad

$$V(x) = \sigma\left(\sum_i \alpha_i s_i(x)\right),$$

donde  $s_i$  son las señales normalizadas de cada capa (anomalía espectral, outlier de persistencia, curvatura, altura de retículo, alcanzabilidad formal),  $\alpha_i$  son pesos (aprendibles) y  $\sigma$  una compresión logística.  $V$  es un ranking, un filtro de Mapper y un campo de costos para la navegación.




Figure 2: El manifold: los nodos son componentes del programa, las aristas son relaciones tipadas. Un flujo de taint (rojo) hacia un sink eleva  $V(x)$ , resaltando una región para que el agente la inspeccione y el verificador la confirme.

## 6 Leyes de mapeo

| #  | Ley                                                      | Clase de vulnerabilidad                      |
|----|----------------------------------------------------------|----------------------------------------------|
| L1 | Cuello de botella ( $\kappa \ll 0$ )                     | escalada de privilegios, bypass de auth      |
| L2 | Ciclo ( $H_1$ persistente)                               | reentrancia, recursión infinita              |
| L3 | Corte de confianza (corte de Fiedler)                    | inyección que cruza la frontera de confianza |
| L4 | Ruptura de naturalidad                                   | violación arbitraria de taint                |
| L5 | Outlier de persistencia                                  | rasgo real vs. espurio                       |
| L6 | Alcanzabilidad ( $\text{SAT}(\Phi \wedge \text{malo})$ ) | exploit concreto                             |

## 7 El agente LLM autónomo

Un ciclo cerrado: (1) *ingesta* hacia la IR; (2) *embebir y mapear* ( $V(x)$ , embedding espectral, persistencia, curvatura, Mapper); (3) *hipotetizar* (el LLM propone candidatos desde el manifold); (4) *verificar* (la capa formal prueba o refuta); (5) *refinar* (los hallazgos re-ponderan y re-embeben); (6) *reportar*. La capa de proveedor LLM apunta a cualquier endpoint compatible con OpenAI mediante **LiteLLM**. El LLM no hace detección cruda: la matemática propone regiones, el LLM propone hipótesis, la capa formal propone pruebas.

## 8 Desafíos de diseño y mitigaciones

Una revisión de diseño identificó cinco riesgos estructurales. Para cada uno enunciamos la mitigación adoptada en el prototipo y el problema abierto.

**C1 – La paradoja del cuello de botella.** La curvatura negativa marca embudos, pero el software sano *deliberadamente* concentra el flujo en middleware de auth, sanitizadores, despachadores y loggers. Reportarlos como leads de escalada de privilegios produce falsos positivos sistemáticos. *Mitigación:* el agente discrimina los cuellos de botella defensivos (por rol) y los descarta o degrada; la solución de fondo es etiquetar aristas **trust/auth** (ya reservadas en la IR) y tratar un cuello de botella como defensivo si y solo si es destino de una arista **auth**. *Abierto:* aprender la etiqueta defensivo/ofensivo a partir de datos.

**C2 – La simetrización destruye la causalidad.** El Laplaciano combinatorio  $L = D - A$  y la homología persistente estándar operan sobre espacios métricos no dirigidos, pero el flujo de control

y de datos es dirigido: que  $A$  manche a  $B$  no es lo mismo que  $B$  manche a  $A$ . Simetrizar puede destruir la dirección del taint. *Mitigación*: el prototipo implementa el Laplaciano dirigido de Chung (componente fuertemente conexa más grande, vector de Perron, conectividad algebraica dirigida), que queda indefinido para un DAG — en sí misma una señal significativa. *Abierto*: complejos de bandera dirigidos / homología de caminos (Grigor’yan–Lin–Muranov–Yau).

**C3 – Costo del transporte óptimo.** Ollivier–Ricci exige un PL de transporte por arista:  $\mathcal{O}(|E| \cdot \text{PL})$ , prohibitivo más allá de  $\sim 10^5$  aristas. *Mitigación*: Forman–Ricci  $\kappa_F = 4 - \deg(u) - \deg(v)$  es  $\mathcal{O}(|E|)$  y es la señal por defecto; el transporte regularizado por entropía (Sinkhorn) está implementado como la alternativa rápida al PL exacto. *Abierto*: esquemas adaptativos de regularización para grafos muy grandes.

**C4 – Operacionalizar L4 (naturalidad).** Se requiere una regla constructiva. Sean las aristas `auth`  $E_A$  las que marcan fronteras de privilegio. Definamos el funtor de autorización  $F$  como la etiqueta de si un nodo es alcanzable *detrás* de una arista `auth`. Entonces un flujo de taint  $s \rightarrow^* k$  *viola la naturalidad* si y solo si su camino cruza al menos una arista `auth` — es decir, datos no confiables entran a una región protegida sin que la frontera los neutralice. Esto es una consulta de alcanzabilidad sobre el grafo combinado ( $\text{dato} \cup \text{taint} \cup \text{auth}$ ), directamente computable y automatizable. *Implementado*: un extractor de autorización emite nodos `gate` y aristas `auth` desde decoradores de frontera de privilegio, y un flujo de taint dentro de una función protegida se reporta como violación de naturalidad.

**C5 – Puente manifold-verificador.** Los rasgos geométricos son cuantitativos; Z3 necesita precondiciones exactas. Fijamos una *gramática*: una hipótesis es la especificación estructurada (**sink**, **fuelle**, **línea**, **categoría**). El manifold aporta la especificación (conoce sink y línea), el LLM aporta la interpretación (CWE, descripción, confianza) y el verificador consume la especificación — nunca la prosa del LLM. Esto mantiene la consulta SMT precisa y reproducible.

La tesis de fondo se sostiene: los analizadores estáticos fallan porque buscan palabras en vez de invariantes en una estructura topológica. El criterio es si  $V(x)$  poda el espacio de búsqueda para Z3/angr de forma más eficiente que un DFS plano sobre el grafo de llamadas.

## 9 Estado de implementación

| Fase | Entregable                                  | Estado    |
|------|---------------------------------------------|-----------|
| F0   | Whitepaper, arquitectura                    | hecho     |
| F1   | IR + ingesta SAST Python + taint            | hecho     |
| F2   | Núcleos espectral + geométrico (Rust)       | hecho     |
| F3   | TDA (homología persistente, Mapper)         | hecho     |
| F4   | Verificación formal (retículo de taint, Z3) | hecho     |
| F5   | Agente LLM autónomo (LiteLLM)               | hecho     |
| F6   | Visualización + demo end-to-end             | hecho     |
| F7   | Adaptadores binario / web / LLM             | pendiente |

## 10 Validación y uso responsable

La validación usa micro-benchmarks de juguete con verdad de referencia conocida, luego corpus etiquetados (OWASP Benchmark, SARD) una vez que F4 aterrice, midiendo precisión/recall del campo fusionado frente al taint crudo. MANIFOLD es una herramienta de defensa / pruebas autorizadas; la liberamos bajo el supuesto de uso autorizado y alentamos la divulgación coordinada.

## References

- [1] M. Fiedler, *Algebraic connectivity of graphs*, 1973.
- [2] F. Chung, *Spectral Graph Theory*, 1997.
- [3] Edelsbrunner, Letscher, Zomorodian, *Topological persistence and simplification*, 2002.
- [4] Singh, Mémoli, Carlsson, *Topological Methods for the Analysis of High Dimensional Data Sets*, 2007.
- [5] Y. Ollivier, *Ricci curvature of Markov chains on metric spaces*, 2009.
- [6] P. Cousot & R. Cousot, *Abstract interpretation: a unified lattice model*, 1977.
- [7] S. Mac Lane, *Categories for the Working Mathematician*, 1971.
- [8] J. King, *Symbolic execution and program testing*, 1976.
- [9] E. M. Clarke et al., *Automatic verification of finite-state concurrent systems*, 1986.
- [10] F. Chung, *Laplacians and the Cheeger inequality for directed graphs*, 2005.
- [11] Grigor'yan, Lin, Muranov, Yau, *Homotopy theory for digraphs*, 2012.
- [12] M. Cuturi, *Sinkhorn distances: lightspeed computation of optimal transport*, 2013.